

Modelos de Inteligencia Artificial Multisensor

Estimación de Biomasa en Bosques Andinos y Pastizales del Ecotono Bosque-Estepa

Fundamentos

Héctor Francisco del Valle

Centro Regional de Geomática (CeReGeo), Facultad de Ciencia y Tecnología (FCyT)

Universidad Autónoma de Entre Ríos (UADER)

Laboratorio de Ecología, Meteorología y Gestión de Fuegos (LEMIV)

Facultad de Ingeniería, Universidad Nacional de la Patagonia San Juan Bosco (UNPSJB)

Correo Electrónico: hfdelvalle@gmail.com

Curso de posgrado · Esquel, Chubut · 14 al 19 de septiembre de 2026

Objetivos de aprendizaje

- | | | |
|---|--------------------|---|
| 1 | Interpretar | Comprender qué mide cada sensor y cómo se vincula con la biomasa. |
| 2 | Seleccionar | Elegir colecciones, resolución, fechas, polarización adecuada, entre otras características. |
| 3 | Diseñar | Plantear comparaciones pre/post que distingan el incendio del efecto estacional. |
| 4 | Validar | Evaluar sesgo, saturación e incertidumbre según las condiciones del ambiente. |

La biomasa es una variable latente

No existe una “banda de biomasa”. El modelo aproxima una variable ecológica usando observables imperfectos.

$AGB = f(\text{óptico, SAR, LiDAR, altura, topografía, historia de fuego....})$

La función f cambia con especie, densidad, humedad, relieve y perturbación.

señal

lo que observa
el sensor

proxy

lo relacionado
con biomasa

modelo

la relación
aprendida

El incendio y la estación pueden producir señales parecidas

Incendio

pérdida de copa, ceniza, suelo expuesto



Sequía

menor humedad y actividad fotosintética



Otoño

senescencia y cambio fenológico




Sombra

relieve, nubes y geometría solar



Solución: comparar fechas de la misma estación y usar polígonos quemados con fecha confiable.

Pre y post deben observar el mismo sistema



PRE: misma estación

Fecha del evento

POST: Respuesta + Recuperación

Fundamentos

Héctor Francisco del Valle

5/40

Tres familias de sensores, tres observables

Familia	Medición	Aporte	Problema	Ejemplos
Óptico	Reflectancia	Pigmentos, área foliar, humedad	Nubes · saturación	Sentinel-2 / Landsat 9
SAR	Retrodispersión	Estructura, agua, rugosidad	Speckle · relieve · ángulo	Sentinel-1 / PALSAR / SAOCOM / NISAR / BIOMASS
LiDAR	Tiempo de retorno	Altura y perfil vertical	Muestreo discontinuo	GEDI L2A / L4A – ICESat2 ATLAS

Conclusión: ningún sensor sustituye a los demás; la sinergia funciona cuando escalas y fechas son comparables.

Fundamentos

Héctor Francisco del Valle

6/40

La IA en este curso

No es un curso de programación: por qué el criterio importa más que el código

- ✓ **La IA ya escribe el código:** lo escaso deja de ser la sintaxis y pasa a ser el **criterio**.
- ✓ **Dirigir un asistente exige conceptos:** qué sensor, qué escala, qué fecha y bajo qué supuestos se pide el resultado.
- ✓ **La validación sigue siendo humana:** la IA produce respuestas **plausibles**, **no necesariamente correctas**.
- ✓ **Dirigido a quienes no dominan Python o JavaScript:** el objetivo es entender qué hacen las herramientas, no escribirlas.

AMPLIFICA

Acelera el código, la exploración y la documentación cuando el problema ya está bien planteado.

NO REEMPLAZA

El criterio de dominio: elegir el dato, juzgar el supuesto y validar el resultado.

La IA baja la barrera del código; por eso mismo sube el valor del criterio.

El problema geográfico: el ecotono

Del bosque húmedo de Nothofagus a la estepa, en pocos kilómetros


- ✓ **Gradiente del bosque húmedo de Nothofagus a la estepa**, a lo largo de Chubut.
- ✓ **Estructura y productividad** cambian abruptamente en distancias muy cortas.
- ✓ **Régimen de incendios** notablemente alterado en las últimas décadas.

Chubut

El mosaico es lo que ningún sensor describe por sí solo: de ahí el enfoque multisensor.

Dónde trabajamos: cobertura forestal del Chubut

Las dos áreas de interés sobre el gradiente bosque–estepa



- ✓ **Verde:** bosque nativo sobre la franja cordillerana; **ocre:** estepa patagónica.
- ✓ **La transición ocurre en pocos kilómetros:** ese estrechamiento es el **ecotono**.
- ✓ **Dos AOI en el noroeste** (recuadros rojos), elegidos para cubrir ambos lados de la transición.
- ✓ **Escala de trabajo:** provincial para el contexto, de AOI para el ajuste y la validación.

Los AOI no son arbitrarios: se ubican donde el gradiente cambia más rápido en menos distancia.

El gradiente oeste–este: del bosque a la estepa


Precipitación decreciente, estructura decreciente: el ecotono es la franja del medio



Cobertura de bosque nativo 2017 en los dos recintos


Bosque y estepa, 15 × 15 km cada uno, sobre la misma grilla de 10 m

Recinto de bosque · BOSQUE_NW_02



Clase agrupada	km²	%
Ñire y otras leñosas	104,41	46,4
Lenga	86,73	38,5
Ciprés	11,04	4,9
Arbustal y matorral	8,77	3,9
Estepa	8,28	3,7
Humedales y agua	3,77	1,7
Otras coberturas	1,99	0,9

Recinto de estepa · ESTEPA_NW_02



Clase agrupada	km²	%
Estepa	190,43	84,6
Lenga	9,56	4,2
Otras coberturas	9,55	4,2
Ñire y otras leñosas	8,45	3,8
Humedales y agua	5,74	2,6
Arbustal y matorral	1,28	0,6

El control no es un caso menor: la estepa aporta el 84,6 % de su recinto y el bosque, el 89,8 % del suyo.

Fuente: Sistema Nacional de Monitoreo de Bosques Nativos, SNMBN (2017). Cobertura de Bosque de la Región Bosque Andino Patagónico, provincia de Chubut 2017 [Conjunto de datos geográficos vectoriales, escala 1:40.000, versión Cobertura BAP 1.0]. Centro de Información Ambiental (CIAM). https://ciam.ambiente.gob.ar/geovisor.php?layer_id=477

¿Por qué multisensor?


Cada sensor responde a una propiedad distinta del terreno

Óptico <i>Sentinel-2 · Landsat-9</i>	Radar (SAR) <i>Sentinel-1 · PALSAR · SAOCOM · NISAR · BIOMASS</i>	LiDAR <i>GEDI · ICESat2_ATLAS</i>
✓ Reflectancia y color ✓ Índices de vegetación (NDVI, EVI) ✓ Estado y vigor foliar ✓ <i>Limitación: nubes y saturación en dosel denso</i>	✓ Estructura y humedad ✓ Penetración de nubes (todo el tiempo) ✓ Bandas L y S: penetración del dosel ✓ Banda P: mayor penetración. ✓ <i>Limitación: saturación en biomasa alta</i>	✓ Estructura vertical 3D ✓ Altura de dosel ✓ Biomasa ✓ <i>Limitación: cobertura espacial parcial</i>

Procesados con aprendizaje automático, el enfoque multisensor se ha consolidado como referencia en paisajes heterogéneos.

Hoja de ruta: los siete apartados

El recorrido completo de la exposición



De la supresión a la anticipación

El giro de la gestión del fuego



- ✓ **Jain et al. (2020)** recorren todo el ciclo: ocurrencia, combustibles, detección temprana, comportamiento e impactos.
- ✓ **Sirve para dimensionar** hasta dónde llega hoy la herramienta y dónde sigue siendo un intento.

Predecir el peligro: modelos e interpretabilidad

De la exactitud a la adopción operativa

- ✓ **Las redes profundas** integran meteorología, estado de la vegetación y teledetección sin especificar cada relación.
- ✓ **Kondylatos et al. (2022)**: interpretabilidad. **Ningún organismo adopta una caja negra.**
- ✓ **Apostolakis et al. (2022), Ejaz y Choudhury (2025), Xu, Z. et al. (2025)**: flujos completos de riesgo diario.
- ✓ **Escala regional**: Gajardo et al. (2025) y Jaque Castillo et al. (2021) en Chile; **Barberá et al. (2025)** en el noroeste patagónico.

Barberá et al. (2025): clima, acumulación de combustible y alternancia de bosque y matorral en el propio ecotono.

Cartografía de combustibles

Del riesgo al mapa: qué arde y dónde

- ✓ **Alipour et al. (2023)**: fusión multisensor con aprendizaje profundo a gran escala.
- ✓ **Carbone et al. (2023)**: redes convolucionales para clasificar tipos de combustible.
- ✓ **Sismanis et al. (2024)** con series temporales de Sentinel-2; **Solares-Canal et al. (2023)** combinando ALS y Sentinel-2.
- ✓ **La carga de combustible es biomasa vista desde el riesgo** (Abdollahi y Yebra, 2025).

Este es el puente entre la gestión del fuego y la teledetección cuantitativa.

La tercera dimensión: humedad del combustible

Regula la inflamabilidad y la velocidad de propagación

Combustible vivo

Rao et al. (2020) con SAR.
Quan et al. (2024), seguimiento sub-diario con Himawari-8.

Combustible fino muerto

Li, Z. et al. (2024) con Landsat.
Wang, W. et al. (2025) con fusión y aprendizaje profundo.

- ✓ **Plano operativo:** Watt et al. (2025) proponen una hoja de ruta para un sistema en tiempo casi real.
- ✓ **Pertinente para el ecotono,** donde la estacionalidad hídrica gobierna la disponibilidad de combustible.

El núcleo: la biomasa como problema de regresión

De la correlación empírica al ajuste no lineal

- ✓ **El planteo:** relacionar variables derivadas de sensores con mediciones de biomasa en el terreno.
- ✓ **Pero es una regresión compleja:** relaciones no lineales y rara vez nítidas.
- ✓ **Consecuencia:** el aprendizaje automático desplazó a los modelos empíricos lineales tradicionales.

$$Y = f(X)$$

No lineal, ruidosa y dependiente del sitio.

Por eso el ajuste importa tanto como el sensor.

Aquí empieza el contenido que sostiene los cinco trabajos prácticos del curso.

La evidencia de la sinergia

¿Qué gana la estimación cuando se suman sensors?

- ✓ **Li, Y. et al. (2020):** Landsat 8 + Sentinel-1A mejora la exactitud frente a un solo sensor.
- ✓ **Wang, C. et al. (2024):** Sentinel-1, Sentinel-2, ALOS PALSAR-2 y GEDI.
- ✓ **Wang, D. et al. (2025):** XGBoost sobre datos multifuente.
- ✓ **Yan et al. (2023):** comparación sistemática que aporta criterios objetivos de selección.
- ✓ **Arquitecturas específicas:** DeepBioFusion (Hanan et al., 2025) y Hemati et al. (2024).

Distinguir bosque aleatorio (Random Forest) de potenciación del gradiente (Gradient Boosting): no son familias intercambiables.

Pastizal y estepa: la mitad relegada

La estepa no es un caso menor del bosque

- ✓ **Fan et al. (2022):** biomasa de pastizales de altura con Sentinel-2 y bosque aleatorio.
- ✓ **Rapiya et al. (2023):** biomasa estacional con Sentinel-1 y Sentinel-2, **análogo directo de la estepa patagónica.**
- ✓ **D'Este et al. (2021) y Bao et al. (2022):** traslado de la estimación a la carga de combustible.

La estepa tiene antecedentes metodológicos propios: no se resuelve extrapolando lo del bosque.

Radar: banda L y soberanía de datos

Por qué la longitud de onda cambia lo que se mide

Banda C · 5,6 cm

Sentinel-1

Serie temporal extensa y geometría estable. Satura pronto en dosel denso.

Banda L · 23,5 cm

SAOCOM · NISAR

Más penetración en el dosel y mayor sensibilidad a la fracción leñosa.

- ✓ **Seppi et al. (2022)**: coherencia interferométrica del SAOCOM en banda L frente a la banda C de Sentinel-1.
- ✓ **Frank Buss et al. (2026)**: polarimetría del SAOCOM-1A sobre el Caldén semiárido argentino.
- ✓ **Horizonte inmediato**: misión **NISAR** (NASA-ISRO), bandas L y **S**, con productos de acceso abierto.

Banda P: el escalón que faltaba

BIOMASS y la señal que llega al tronco

Banda C · 5,6 cm

Sentinel-1

Banda L · 23,5 cm

SAOCOM · NISAR

Banda P · ~70 cm

BIOMASS (ESA) · primer SAR en banda P

Qué aporta la banda P

Penetra el dosel y responde a troncos y ramas gruesas, donde está la mayor parte del carbono.
Satura mucho más tarde que C y L: mide donde las otras bandas ya no distinguen.
Sensible a la fracción leñosa, no a la hoja.

La misión, en datos

Lanzada el 29/04/2025 · primer SAR en banda P en órbita.
Reflector de malla desplegable de 12 m.
Biomasa y altura a 200 m; disturbio a 50 m, cada 6 meses.
Nivel 1 abierto desde enero de 2026; Nivel 2 en liberación por fases durante 2026.

Atención a la escala: dentro del AOI los 200 m sirven para estadísticas y validación de paisaje, pero no para interpretar detalles menores a ese soporte.

Fuente: ESA (2026). Biomass (Earth Explorer 7). https://www.esa.int/Applications/Observing_the_Earth/FutureEO/Biomass

Los 200 m de BIOMASS: qué permiten y qué no

Compatibilidad de escalas en AOI de 15 × 15 km

SÍ

Estadísticas internas del AOI de 15 × 15 km.

Comparación y validación a escala de paisaje.

CON CONDICIONES

Uso en el ajuste, siempre que las variables y observaciones se armonicen a su soporte espacial de 200 m.

NO

Referencia directa para variación a escala de parcela.

Insumo para modelos de 10–30 m.

No confundir con CCI Biomass: producto de 100 m basado principalmente en SAR de bandas C y L, complementado con información lidar — no en la banda P de la misión BIOMASS.

CCI Biomass: qué mide, con qué sensores y en qué años

Componente	Sensores	Aporte al producto	Épocas	Salida
SAR banda L	ALOS PALSAR / ALOS-2 PALSAR-2	Sensibilidad a la fracción leñosa	2005–2012 · 2015–2024	AGB en Mg/ha, 100 m
SAR banda C	Sentinel-1 · Envisat ASAR	Continuidad y densidad temporal	2015–2024 · épocas tempranas	Capa de incertidumbre por píxel
LiDAR de calibración	ICESat GLAS · ICESat-2 · GEDI	Altura y estructura del dosel	Calibración según el año	Mapas anuales comparables

Versión 7.0 (2026): AGB anual para 2005–2012 y 2015–2024 · <https://climate.esa.int/en/projects/biomass/data/> · datos en el archivo CEDA.

CCI Biomass en el ecotono: alcance y cautelas

Qué se puede sostener con un producto global de 100 m

Alcance · 100 m

Contexto y comparación

Referencia externa de los órdenes de magnitud y del gradiente bosque–estepa a escala de paisaje.

Cautelas

Biomasa baja y cambio

En la estepa la incertidumbre relativa es alta; las diferencias entre versiones no son cambio real.

- ✓ **Épocas disponibles:** series anuales 2005–2012 y 2015–2024 en la versión 7.0 del producto.
- ✓ **Uso razonable:** covariable o comparación externa, armonizada al soporte de 100 m y con la incertidumbre propagada.
- ✓ **Acceso verificable:** <https://climate.esa.int/en/projects/biomass/data/>

[Santoro y Cartus \(2025\)](#)

Qué algoritmo y para qué

Cuatro familias, cuatro compromisos distintos

Familia	Fortalezas	Cautelas
Random Forest	Robusto; entrega importancia de variables	Tiende a saturar en biomasa alta
XGBoost / Gradient Boosting	Alta exactitud; capta no linealidades	Exige ajuste; riesgo de sobreajuste
Redes profundas (CNN, LSTM)	Patrones espaciales y temporales	Muchos datos; menor interpretabilidad
SVR / k-NN	Simples; útiles con pocas muestras	Limitados en alta dimensión

Ninguna familia domina en todo: la elección depende del tamaño de la muestra y del rango de biomasa.

El diluvio de datos satelitales

El problema cambió de signo

Petabytes

que se renuevan sin pausa

Landsat, Sentinel, GEDI y SAOCOM, en archivos abiertos.


- ✓ Archivos Landsat abiertos, constelación Sentinel, GEDI y SAOCOM: el volumen se renueva más rápido de lo que se consume.
- ✓ El problema cambió de signo: no escasean las imágenes; escasea la capacidad de almacenar, procesar y extraer.
- ✓ Gomes et al. (2020) comparan las plataformas de análisis a escala de petabyte.

No falta el dato: falta el criterio para usarlo.

La respuesta: nube, cómputo distribuido y series temporales

Acercar el procesamiento a donde residen los datos

- ✓ Yao et al. (2020), Xu, C. et al. (2022) y Guo et al. (2022): arquitecturas distribuidas y sistemas en contenedores.
- ✓ Idea de fondo: acercar el procesamiento a donde residen los datos.
- ✓ Reto analítico, no solo de infraestructura: fenología y detección de perturbaciones (Fu et al., 2024).
- ✓ Dimensión humana: la adopción depende de la formación y de las barreras de acceso (Wagemann et al., 2021).



Representación conceptual del crecimiento de los archivos de observación de la Tierra: no es una medición.

Herramientas y plataformas

Con qué se trabaja, según dónde se trabaje

Nube

Google Earth Engine · openEO · Microsoft Planetary Computer · AWS Open Data

Escritorio

ESA SNAP para SAR y ópticos · QGIS para visualización y análisis

Código

Python (scikit-learn, PyTorch, GDAL, rasterio) · R (caret, randomForest, terra)

Datos de referencia

GEDI L4A a nivel de huella y L4B grillado, de acceso abierto


openEO importa por reproducibilidad y por no depender de un único proveedor.

Colecciones en Google Earth Engine: qué hay y desde cuándo

Familia	Colección en GEE	Resolución	Cobertura temporal	Uso en biomasa
Óptico	COPERNICUS/S2_SR_HARMONIZED · LANDSAT/LC08 y LC09/C02/T1_L2	10–20 m 30 m	2017– 2013–2021	Índices, composiciones estacionales
SAR	COPERNICUS/S1_GRD (banda C) · JAXA/ALOS/PALSAR/YEARLY/SAR_EPOCH (banda L)	10 m 25 m	2014– 2007– 2010 2015 – 2021	Estructura y humedad, sin dependencia de nubes
LiDAR	GEDI L2A y L4A por huella · GEDI L4B grillado	25 m 1 km	2019 - · 2019 - 2021	Altura, perfil vertical y AGBD de referencia

Embeddings: GOOGLE/SATELLITE_EMBEDDING/V1/ANNUAL · 10 m · 2017–2025 · 64 dimensiones que resumen óptico, radar y lidar en un vector por píxel.

Del conjunto de piezas al flujo de trabajo



- ✓ **Cadena completa:** adquisición, preprocesamiento, extracción de variables, modelado, validación de campo y producto final, con ciclos de retroalimentación que obligan a reajustar el modelo.
- ✓ **Vanguardia:** Shendryk (2022) con fusión GEDI-EO de extremo a extremo; Jiang et al. (2025). **Exigencia creciente:** reproducibilidad, datos FAIR y cubos de datos.

Acceso abierto y democratización

Abrir el archivo fue condición necesaria, no suficiente

- ✓ **La liberación del archivo Landsat en 2008** marcó un antes y un después (Wulder et al., 2022).
- ✓ **Copernicus adoptó la misma filosofía;** Sawyer et al. (2022) cuantifican su valor.
- ✓ **Democratizar exige además** cómputo, software libre y formación.

El SAOCOM (CONAE) como activo estratégico: soberanía de datos en banda L.

Alcances, límites y consideración final

¿Qué puede y qué no puede sostener este marco?

- ✓ **Marco conceptual y selección de referencias:** no reemplaza la formación en programación ni en teledetección.
- ✓ **Tres límites documentados:** saturación de la señal en biomasa alta, incertidumbre y dependencia de datos de campo.
- ✓ **Transferibilidad:** el desempeño decae al aplicar los modelos fuera del área de entrenamiento (Chen et al., 2023).
- ✓ **Anclaje local:** Loguercio et al. (2024), Taylor-Zavala et al. (2021), Peri et al. (2024), Curcio et al. (2023) y Seppi et al. (2024).

Estas herramientas no reemplazan el criterio de quien conoce el campo: lo extienden.

Referencias bibliográficas (1/6)

- Abdollahi, A., & Yebra, M. (2025). Challenges and opportunities in remote sensing-based fuel load estimation for wildfire behavior and management: A comprehensive review. *Remote Sensing*, 17(3), 415. <https://doi.org/10.3390/rs17030415>
- Alipour, M., La Puma, I., Picotte, J., Shamsaei, K., Rowell, E., Watts, A., Kosovic, B., Ebrahimian, H., & Taciroglu, E. (2023). A multimodal data fusion and deep learning framework for large-scale wildfire surface fuel mapping. *Fire*, 6(2), 36. <https://doi.org/10.3390/fire6020036>
- Apostolakis, A., Girtsou, S., Giannopoulos, G., Bartsotas, N. S., & Kontoes, C. (2022). Estimating next day's forest fire risk via a complete machine learning methodology. *Remote Sensing*, 14(5), 1222. <https://doi.org/10.3390/rs14051222>
- Bao, W., Yu, F., Chang, Y., Guo, M., Zhou, F., & Zhong, C. (2022). Estimation of fuel load using remote sensing data in Hulunbuir Grassland. *Natural Hazards Research*, 2, 375-383. <https://doi.org/10.1016/j.nhres.2022.11.004>
- Barberá, I., Cingolani, A. M., Tiribelli, F., Mermoz, M. A., Morales, J. M., & Kitzberger, T. (2025). Biotic and physical drivers of fire in northwestern Patagonia. *Fire Ecology*, 21, 14. <https://doi.org/10.1186/s42408-025-00353-8>
- Carbone, A., Spiller, D., & Laneve, G. (2023). Fuel type mapping using a CNN-based remote sensing approach: A case study in Sardinia. *Fire*, 6(10), 395. <https://doi.org/10.3390/fire6100395>
- Chen, L., Lin, H., Long, J., Liu, Z., Yang, P., & Zhang, T. (2023). Evaluating the transferability of spectral variables and prediction models for mapping forest aboveground biomass using transfer learning methods. *Remote Sensing*, 15(22), 5358. <https://doi.org/10.3390/rs15225358>
- Curcio, M., Irisarri, G., García Martínez, G., & Oesterheld, M. (2023). Trends of aboveground net primary productivity of Patagonian meadows, the omitted ecosystem in desertification studies. *Remote Sensing*, 15(10), 2531. <https://doi.org/10.3390/rs15102531>

Referencias bibliográficas (2/6)

- D'Este, M., Elia, M., Giannico, V., Spano, G., Laforzezza, R., & Sanesi, G. (2021). Machine learning techniques for fine dead fuel load estimation using multi-source remote sensing data. *Remote Sensing*, 13(9), 1658. <https://doi.org/10.3390/rs13091658>
- Ejaz, N., & Choudhury, S. (2025). A comprehensive survey of the machine learning pipeline for wildfire risk prediction and assessment. *Ecological Informatics*, 90, 103325. <https://doi.org/10.1016/j.ecoinf.2025.103325>
- European Space Agency. (2026). Biomass: the forest mission (Earth Explorer 7) [Misión satelital]. ESA. https://www.esa.int/Applications/Observing_the_Earth/FutureEO/Biomass
- Fan, X., He, G., Zhang, W., Long, T., Zhang, X., Wang, G., Sun, G., Zhou, H., Shang, Z., Tian, D., Li, X., & Song, X. (2022). Sentinel-2 images based modeling of grassland above-ground biomass using random forest algorithm: A case study on the Tibetan Plateau. *Remote Sensing*, 14(21), 5321. <https://doi.org/10.3390/rs14215321>
- Frank Buss, E., Argañaraz, J. P., & Frery, A. C. (2026). Exploratory data analysis from SAOCOM-1A polarimetric images over forest attributes of the semiarid Caldén (Neltuma caldenia) forest, Argentina. *Sustainability*, 18(1), 369. <https://doi.org/10.3390/su18010369>
- Fu, Y., Zhu, Z., Liu, L., Zhan, W., He, T., Shen, H., Zhao, J., Liu, Y., Zhang, H., Liu, Z., Xue, Y., & Ao, Z. (2024). Remote sensing time series analysis: A review of data and applications. *Journal of Remote Sensing*, 4, 0285. <https://doi.org/10.34133/remotesensing.0285>
- Gajardo, J., Yáñez, M., Padilla, R., Espinoza, S., & Carrasco-Benavides, M. (2025). Modeling the spatial distribution of wildfire risk in Chile under current and future climate scenarios. *Fire*, 8(3), 113. <https://doi.org/10.3390/fire8030113>
- Gomes, V. C. F., Queiroz, G. R., & Ferreira, K. R. (2020). An overview of platforms for big Earth observation data management and analysis. *Remote Sensing*, 12(8), 1253. <https://doi.org/10.3390/rs12081253>
- Guo, J., Huang, C., & Hou, J. (2022). A scalable computing resources system for remote sensing big data processing using GeoPySpark based on Spark on K8s. *Remote Sensing*, 14(3), 521. <https://doi.org/10.3390/rs14030521>

Referencias bibliográficas (3/6)

- Hanan, A., Khan, M., Fernandez-Anez, N., & Arghandeh, R. (2025). DeepBioFusion: Multi-modal deep learning based above ground biomass estimation using SAR and optical satellite images. *Ecological Informatics*, 90, 103277. <https://doi.org/10.1016/j.ecoinf.2025.103277>
- Hemati, M., Mahdianpari, M., Shiri, H., & Mohammadimanesh, F. (2024). Integrating SAR and optical data for aboveground biomass estimation of coastal wetlands using machine learning: Multi-scale approach. *Remote Sensing*, 16(5), 831. <https://doi.org/10.3390/rs16050831>
- Ibrahim, R. E., El-Magd, I. A., Motshegwa, T., Ead, H. A., Ogot, M., Wafula, J., Abotalib, A. Z., Mchunu, N. P., Hachigonta, S., Kinyuru, J., & Ali, E. M. (2024). The role of open science and geoinformatics in advancing sustainable development goals in Africa: A strategic framework and an action plan. *Data Science Journal*, 23(1), 47. <https://doi.org/10.5334/dsj-2024-047>
- Jain, P., Coogan, S. C. P., Subramanian, S. G., Crowley, M., Taylor, S., & Flannigan, M. D. (2020). A review of machine learning applications in wildfire science and management. *Environmental Reviews*, 28(4), 478-505. <https://doi.org/10.1139/er-2020-0019>
- Jaque Castillo, E., Fernández, A., Fuentes Robles, R., & Ojeda, C. G. (2021). Data-based wildfire risk model for Mediterranean ecosystems – Case study of the Concepción metropolitan area in central Chile. *Natural Hazards and Earth System Sciences*, 21(12), 3663-3678. <https://doi.org/10.5194/nhess-21-3663-2021>
- Jiang, W., Zhang, L., Zhang, X., Gao, S., Gao, H., Sun, L., & Yan, G. (2025). Multi-Decision Vector Fusion Model for enhanced mapping of aboveground biomass in subtropical forests integrating Sentinel-1, Sentinel-2, and airborne LiDAR data. *Remote Sensing*, 17(7), 1285. <https://doi.org/10.3390/rs17071285>
- Kondylatos, S., Prapas, I., Ronco, M., Papoutsis, I., Camps-Valls, G., Piles, M., Fernández-Torres, M.-Á., & Carvalhais, N. (2022). Wildfire danger prediction and understanding with deep learning. *Geophysical Research Letters*, 49(17), e2022GL099368. <https://doi.org/10.1029/2022GL099368>
- Li, Y., Li, M., Li, C., & Liu, Z. (2020). Forest aboveground biomass estimation using Landsat 8 and Sentinel-1A data with machine learning algorithms. *Scientific Reports*, 10, 9952. <https://doi.org/10.1038/s41598-020-67024-3>
- Li, Z., Wu, Z., Zhu, S., Hou, X., & Li, S. (2024). Estimation of understory fine dead fuel moisture content in subtropical forests of southern China based on Landsat images. *Forests*, 15(11), 2002. <https://doi.org/10.3390/f15112002>

Referencias bibliográficas (4/6)

- Loguercio, G. A., Simon, A., Winter, A. N., Ivancich, H., Reiter, E. J., Caselli, M., Heinzle, F. G., Leuschner, C., & Walentowski, H. (2024). Carbon density and sequestration in the temperate forests of northern Patagonia, Argentina. *Frontiers in Forests and Global Change*, 7, 1373187. <https://doi.org/10.3389/ffgc.2024.1373187>
- Peri, P. L., Gaitán, J., Díaz, B., Almonacid, L., Morales, C., Ferrer, F., Lasagno, R., Rodríguez-Souilla, J., & Martínez Pastur, G. (2024). Vegetation type mapping in southern Patagonia and its relationship with ecosystem services, soil carbon stock, and biodiversity. *Sustainability*, 16(5), 2025. <https://doi.org/10.3390/su16052025>
- Quan, X., Chen, R., Yebra, M., Riaño, D., Resco de Dios, V., Li, X., He, B., Nolan, R. H., Griebel, A., Boer, M. M., & Sun, Y. (2024). Sub-daily live fuel moisture content estimation from Himawari-8 data. *Remote Sensing of Environment*, 308, 114170. <https://doi.org/10.1016/j.rse.2024.114170>
- Rao, K., Williams, A. P., Fortin Flefil, J., & Konings, A. G. (2020). SAR-enhanced mapping of live fuel moisture content. *Remote Sensing of Environment*, 245, 111797. <https://doi.org/10.1016/j.rse.2020.111797>
- Rapiya, M., Ramoelo, A., & Truter, W. (2023). Seasonal evaluation and mapping of aboveground biomass in natural rangelands using Sentinel-1 and Sentinel-2 data. *Environmental Monitoring and Assessment*, 195(12), 1544. <https://doi.org/10.1007/s10661-023-12133-5>
- Santoro, M., Cartus, O. (2025): ESA Biomass Climate Change Initiative (Biomass_cci): Global datasets of forest above-ground biomass for the years 2007, 2010, 2015, 2016, 2017, 2018, 2019, 2020, 2021 and 2022, v6.0. NERC EDS Centre for Environmental Data Analysis, 17 April 2025. doi:10.5285/95913ffb6467447ca72c4e9d8cf30501. <https://dx.doi.org/10.5285/95913ffb6467447ca72c4e9d8cf30501>
- Sawyer, G., Mamais, E., & Papadakis, D. (2022). The six dimensions of value associated to the use of Copernicus Sentinel data: Key findings from the Sentinel benefits study. *Frontiers in Environmental Science*, 10, 804862. <https://doi.org/10.3389/fenvs.2022.804862>
- Seppi, S. A., López-Martínez, C., & Joseau, M. J. (2022). Assessment of L-band SAOCOM InSAR coherence and its comparison with C-band: A case study over managed forests in Argentina. *Remote Sensing*, 14(22), 5652. <https://doi.org/10.3390/rs14225652>
- Seppi, S. A., López-Martínez, C., & Joseau, M. J. (2024). An assessment of SAOCOM L-band PolInSAR capabilities for canopy height estimation: A case study over managed forests in Argentina. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 17. <https://doi.org/10.1109/JSTARS.2024.3363435>

Referencias bibliográficas (5/6)

- Shendryk, Y. (2022). Fusing GEDI with Earth observation data for large area aboveground biomass mapping. *International Journal of Applied Earth Observation and Geoinformation*, 115, 103108. <https://doi.org/10.1016/j.jag.2022.103108>
- Sistema Nacional de Monitoreo de Bosques Nativos. (2017). Cobertura de bosque de la Región Bosque Andino Patagónico, provincia de Chubut 2017 (Versión Cobertura BAP 1.0) [Conjunto de datos geográficos vectoriales, escala 1:40.000]. Ministerio de Ambiente y Desarrollo Sostenible, Centro de Información Ambiental. https://ciam.ambiente.gob.ar/geovisor.php?layer_id=477
- Sismanis, M., Gitas, I. Z., Stavroudis, D., Georgopoulos, N., Antoniadis, K., & Gkounti, E. (2024). A novel spectral-spatial methodology for hierarchical fuel type mapping in Mediterranean ecosystems using Sentinel-2 timeseries and auxiliary thematic data. *Fire*, 7(11), 407. <https://doi.org/10.3390/fire7110407>
- Solares-Canal, A., Alonso, L., Rincón, T., Picos, J., Molina-Terrén, D. M., Becerra, C., & Armesto, J. (2023). Operational fuel model map for Atlantic landscapes using ALS and Sentinel-2 images. *Fire Ecology*, 19, 61. <https://doi.org/10.1186/s42408-023-00218-y>
- Taylor-Zavala, R., Ramírez-Rodríguez, O., de Armas-Ricard, M., Sanhueza, H., Higuera-Fredes, F., & Mattar, C. (2021). Quantifying biochemical traits over the Patagonian sub-Antarctic forests and their relation to multispectral vegetation indices. *Remote Sensing*, 13(21), 4232. <https://doi.org/10.3390/rs13214232>
- Wagemann, J., Siemen, S., Seeger, B., & Bendix, J. (2021). Users of open big Earth data – An analysis of the current state. *Computers & Geosciences*, 157, 104916. <https://doi.org/10.1016/j.cageo.2021.104916>
- Wang, C., Zhang, W., Ji, Y., Marino, A., Li, C., Wang, L., Zhao, H., & Wang, M. (2024). Estimation of aboveground biomass for different forest types using data from Sentinel-1, Sentinel-2, ALOS PALSAR-2, and GEDI. *Forests*, 15(1), 215. <https://doi.org/10.3390/f15010215>
- Wang, D., Xing, Y., Fu, A., Tang, J., Chang, X., Yang, H., Yang, S., & Li, Y. (2025). Mapping forest aboveground biomass using multi-source remote sensing data based on the XGBoost algorithm. *Forests*, 16(2), 347. <https://doi.org/10.3390/f16020347>
- Wang, W., Zhou, C., Zhang, J., Li, Y., Chen, Z., & Luo, Y. (2025). A novel approach for inverting forest fuel moisture content utilizing multi-source remote sensing and deep learning. *Forests*, 16(9), 1423. <https://doi.org/10.3390/f16091423>

Referencias bibliográficas (6/6)

- Watt, M. S., Gross, S., Difuntorum, J. K., McCarty, J. L., Pearce, H. G., Shuman, J. K., & Yebra, M. (2025). Monitoring wildfire risk with a near-real-time live fuel moisture content system: A review and roadmap for operational application in New Zealand. *Remote Sensing*, 17(21), 3580. <https://doi.org/10.3390/rs17213580>
- Wulder, M. A., Roy, D. P., Radeloff, V. C., Loveland, T. R., Anderson, M. C., Johnson, D. M., ... Cook, B. D. (2022). Fifty years of Landsat science and impacts. *Remote Sensing of Environment*, 280, 113195. <https://doi.org/10.1016/j.rse.2022.113195>
- Xu, C., Du, X., Fan, X., Giuliani, G., Hu, Z., Wang, W., Liu, J., Wang, T., Yan, Z., Zhu, J., Jiang, T., & Guo, H. (2022). Cloud-based storage and computing for remote sensing big data: A technical review. *International Journal of Digital Earth*, 15(1), 1417-1445. <https://doi.org/10.1080/17538947.2022.2115567>
- Xu, Z., Li, J., Cheng, S., Rui, X., Zhao, Y., He, H., Guan, H., Sharma, A., Erxleben, M., Chang, R., & Xu, L. L. (2025). Deep learning for wildfire risk prediction: Integrating remote sensing and environmental data. *ISPRS Journal of Photogrammetry and Remote Sensing*, 227, 632-677. <https://doi.org/10.1016/j.isprsjprs.2025.06.002>
- Yan, X., Li, J., Smith, A. R., Yang, D., Ma, T., Su, Y., & Shao, J. (2023). Evaluation of machine learning methods and multi-source remote sensing data combinations to construct forest above-ground biomass models. *International Journal of Digital Earth*, 16(2), 4471-4491. <https://doi.org/10.1080/17538947.2023.2270459>
- Yao, X., Li, G., Xia, J., Ben, J., Cao, Q., Zhao, L., Ma, Y., Zhang, L., & Zhu, D. (2020). Enabling the big Earth observation data via cloud computing and DGGS: Opportunities and challenges. *Remote Sensing*, 12(1), 62. <https://doi.org/10.3390/rs12010062>

Acrónimos y siglas

AGB — Biomasa aérea (Aboveground Biomass)	InSAR / PolInSAR — Interferometría SAR / Interferometría SAR polarimétrica
ALOS PALSAR — Advanced Land Observing Satellite / Phased Array L-band SAR (JAXA)	k-NN — k vecinos más cercanos (k-Nearest Neighbors)
ALS — Escaneo láser aerotransportado (Airborne Laser Scanning)	LiDAR — Light Detection and Ranging
AOI — Área de interés (Area of Interest)	LSTM — Memoria de largo y corto plazo (Long Short-Term Memory)
BIOMASS — Misión SAR en banda P de la ESA (Earth Explorer 7)	NASA — National Aeronautics and Space Administration (EE. UU.)
CCI — Climate Change Initiative (ESA)	NDVI — Índice de vegetación de diferencia normalizada
CNN — Red neuronal convolucional (Convolutional Neural Network)	NISAR — NASA-ISRO Synthetic Aperture Radar (bandas L y S)
CONAE — Comisión Nacional de Actividades Espaciales (Argentina)	QGIS — Quantum GIS (software libre de análisis geoespacial)
EO — Observación de la Tierra (Earth Observation)	SAOCOM — Satélite Argentino de Observación con Microondas (banda L, CONAE)
ESA — Agencia Espacial Europea (European Space Agency)	SAR — Radar de apertura sintética (Synthetic Aperture Radar)
EVI — Índice de vegetación mejorado (Enhanced Vegetation Index)	SNAP — Sentinel Application Platform (ESA)
FAIR — Findable, Accessible, Interoperable, Reusable (principios de datos)	SNMBN — Sistema Nacional de Monitoreo de Bosques Nativos
GEDI — Global Ecosystem Dynamics Investigation (LiDAR espacial de la NASA)	SVR — Regresión de vectores de soporte (Support Vector Regression)
IA — Inteligencia artificial	XGBoost — Extreme Gradient Boosting
ICESat-2 / ATLAS — Ice, Cloud and land Elevation Satellite-2 / Advanced Topographic Laser Altimeter System	